Projekt5_Nocoń_Filip

December 10, 2025

1 Projekt 5

1.1 ## Filip Nocoń

1.1.1 Inicjalizacja potrzebnych bibliotek

[1]:
```
# Tutaj należy zaimport pandas as pdimportować potrzebne biblioteki.:
import pandas as pd
import matplotlib.pyplot as plt

import seaborn as sns
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

import plotly.graph_objs as go
import plotly.offline as py

import numpy as np
%matplotlib inline
```

1.1.2 1. Wczytanie plików z danymi. Perzypisanie nazw x0, x1,... poszczególnym kolumnom.

[2]:
```
df = pd.read_csv("dane_13.csv", sep=',')

scaler = StandardScaler()
data_scaled = scaler.fit_transform(df.dropna())
df_scaled = pd.DataFrame(data_scaled, columns=df.columns)
print(df_scaled.head())
```

```
        X_0       X_1       X_2       X_3       X_4       X_5       X_6  \
0 -1.354284 -0.470377 -0.019883 -0.961239 -1.073798  1.139953  1.039506
1  0.212528 -0.391066  1.612919  0.525275 -1.488323  0.744285  0.458273
2  0.752676  0.857874  0.658064  0.089127  0.227501  0.587212 -1.192316
3  0.498792 -0.288700  0.981941 -0.544080 -0.980427  0.727019  0.395030
4  0.192180  0.201166 -0.612965 -0.827399 -0.004469 -1.257857 -0.242687
```

```
        X_7
0 -1.002138
1  1.949937
2  0.461208
3  1.749740
4  0.555910
```

1.1.3 2. Centrowanie danych. Macierzowy wykres rozrzutu

[3]:
```
sns.pairplot(
    df_scaled,
    vars=df_scaled.columns,
    diag_kind="hist",
    plot_kws={"alpha": 0.6, "s": 40}
)

plt.suptitle("Macierzowy wykres rozrzutu dla danych standaryzowanych", y=1.02)
plt.show()
```

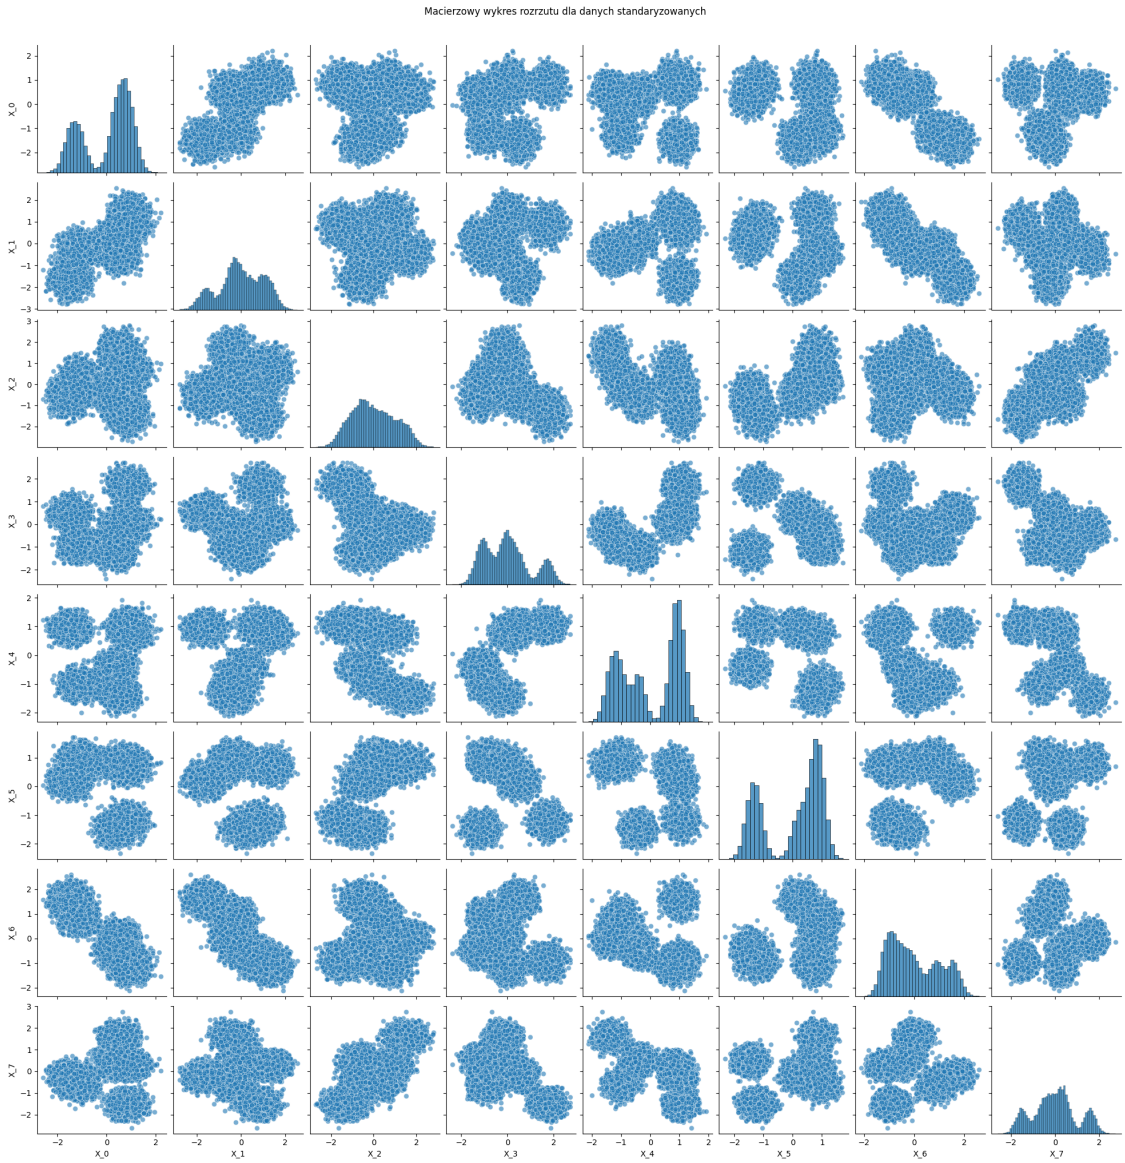

1.1.4 3. Analiza PCA

[4]:
```
pca = PCA()
pca.fit(data_scaled)
variance = pca.explained_variance_ratio_
cumsum_variance = np.cumsum(variance)
indeks = range(1,len(variance)+1)

i=0
cum_sum = 0
```

```
for PC in variance:
    i+=1
    cum_sum+=PC
    print(f"PC_{i}: {PC*100:.2f}")
    print(f"suma dla {i} : {cum_sum}")
```

```
PC_1: 41.54
suma dla 1 : 0.4153630956145409
PC_2: 30.70
suma dla 2 : 0.7223437356795384
PC_3: 12.28
suma dla 3 : 0.8451713217149409
PC_4: 7.54
suma dla 4 : 0.9205280463598748
PC_5: 4.20
suma dla 5 : 0.9625147358775705
PC_6: 1.46
suma dla 6 : 0.9770681553986084
PC_7: 1.23
suma dla 7 : 0.9893244869611054
PC_8: 1.07
suma dla 8 : 1.0
```

Określ liczbę składowych głównych, która wyjaśniałaby co najmniej 90% zmienności zbioru danych.

4 - PC1,2,3,4. Widać też to przejrzyście na wykresie.

[5]:
```
plt.figure(figsize=(10, 6))
plt.plot(indeks, variance * 100, marker='o', linestyle='-', color='blue')
plt.title('Procent wariancji wyjaśnionej w zależności od składowej głównej')
plt.xlabel('Składowe Główne PC')
plt.ylabel('Procent Wariancji Wyjaśnionej (%)')
plt.grid(True)
plt.show()
```

[6]:
```
plt.figure(figsize=(10, 6))
plt.plot(indeks, cumsum_variance * 100, marker='o', linestyle='-', color='red')
plt.title('Procent skumulowanej wariancji wyjaśnionej w zależności od składowej␣
↪głównej')
plt.xlabel('Składowe Główne PC')
plt.ylabel('Procent Skumulowanej Wariancji Wyjaśnionej (%)')
plt.axhline(y=90, color='grey', linestyle='--', label='Próg 90%')
plt.legend()
plt.grid(True)
plt.show()
```

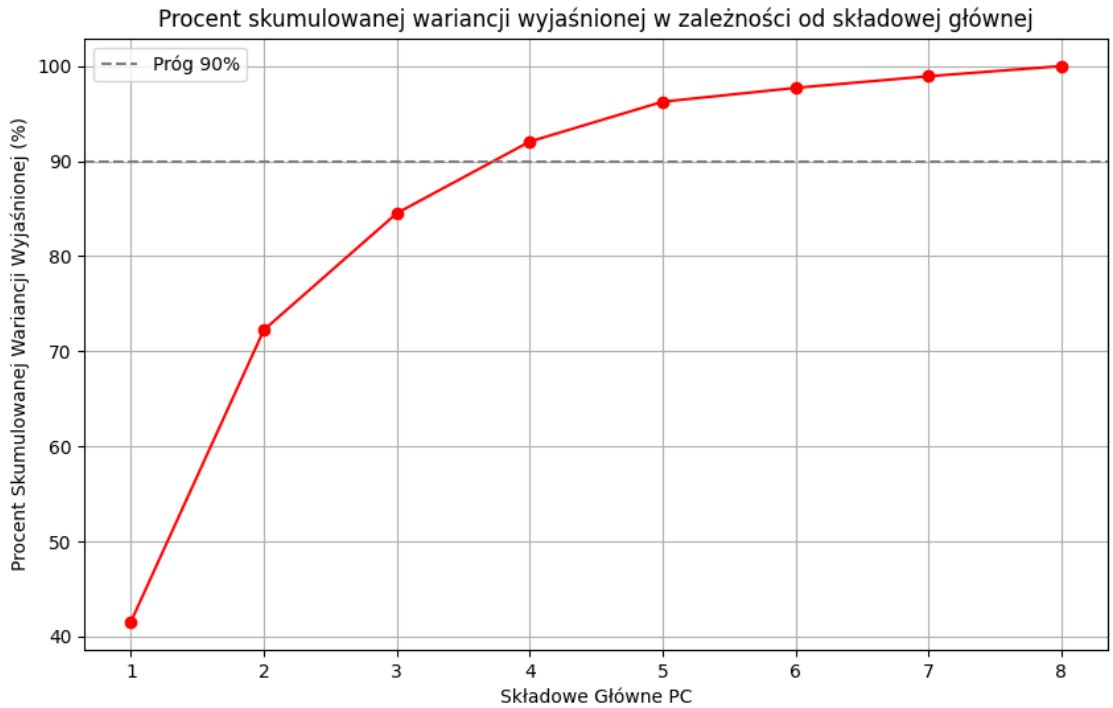

1.1.5 4. Rzutowanie obserwacji na przestrzeń 2D

[7]:
```
pca_2d = PCA(n_components=2)
data_2d = pca_2d.fit_transform(data_scaled)

variance_2d = pca_2d.explained_variance_ratio_.sum()
print(f"\nSkumulowana wariancja wyjaśniona dla 2 składowych głównych (PC1, PC2):
 ↪ {variance_2d*100:.2f}%")

plt.figure(figsize=(8, 8))
plt.scatter(data_2d[:, 0], data_2d[:, 1], alpha=0.7, s=50)
plt.title('Rzutowanie obserwacji na przestrzeń 2D (PC1 vs PC2)')
plt.xlabel(f'Składowa Główna 1 (PC1) - Wyjaśnia {pca_2d.
 ↪explained_variance_ratio_[0]*100:.2f}% Wariancji')
plt.ylabel(f'Składowa Główna 2 (PC2) - Wyjaśnia {pca_2d.
 ↪explained_variance_ratio_[1]*100:.2f}% Wariancji')
plt.grid(True)
plt.show()
```

```
Skumulowana wariancja wyjaśniona dla 2 składowych głównych (PC1, PC2): 72.23%
```

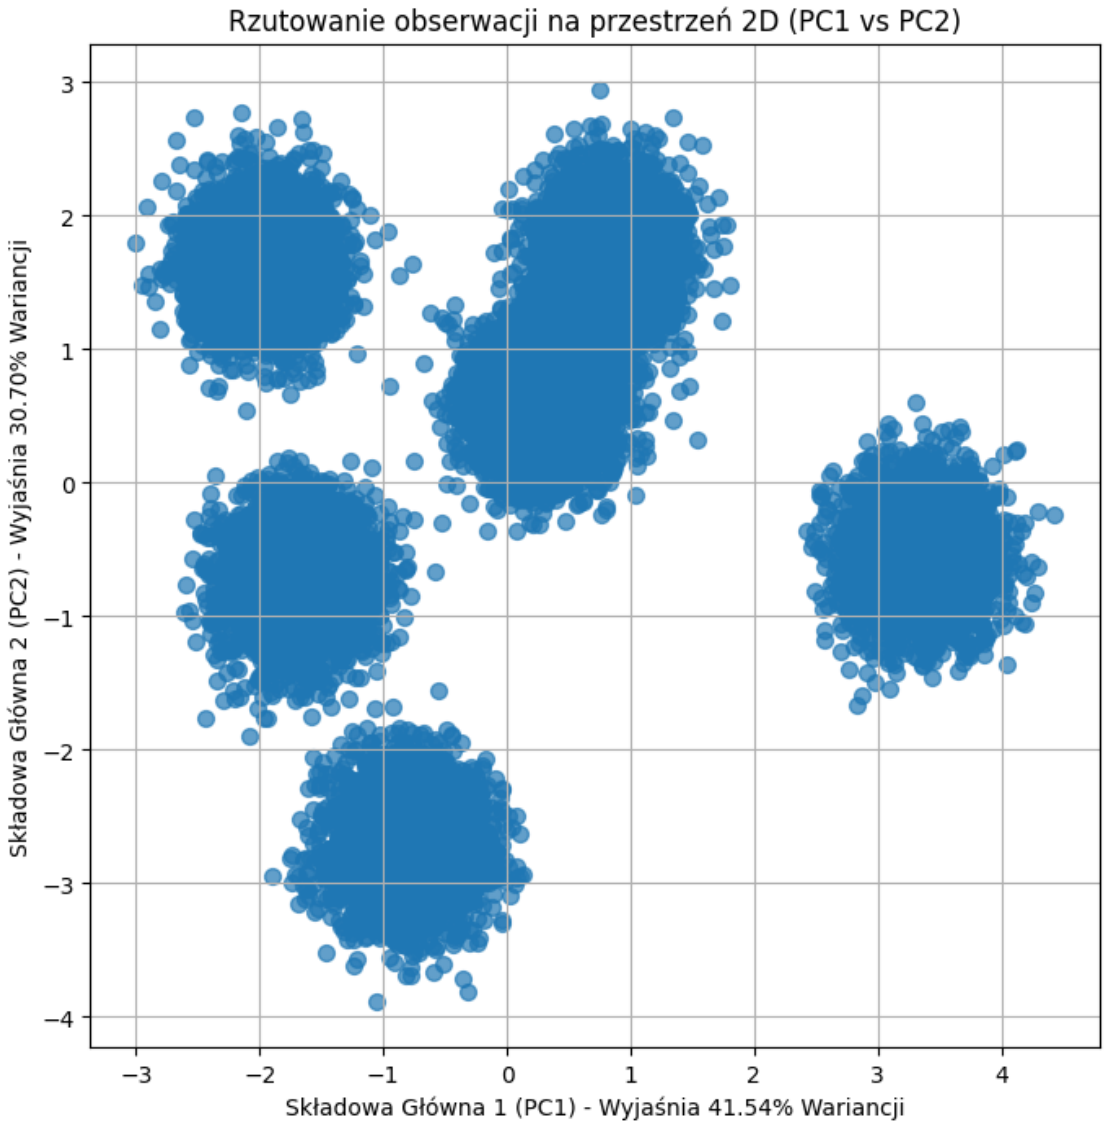

1.1.6 5. Rzutowanie obserwacji na przestrzeń 3D

[8]:
```
pca_3d = PCA(n_components=3)
data_3d = pca_3d.fit_transform(data_scaled)

variance_3d = pca_3d.explained_variance_ratio_.sum()
print(f"\nSkumulowana wariancja wyjaśniona dla 3 składowych głównych (PC1, PC2,␣
↪PC3): {variance_3d*100:.2f}%")

py.init_notebook_mode(connected=True)
```

```
trace = go.Scatter3d(
    x=data_3d[:, 0],
    y=data_3d[:, 1],
    z=data_3d[:, 2],

    mode='markers',
    marker={
        'size': 5,
        'opacity': 0.8,
        'color': data_3d[:, 2],
        'colorscale': 'Viridis'
    },
    name='Obserwacje'
)


layout = go.Layout(
    title='Rzutowanie obserwacji na przestrzeń 3D (PC1, PC2, PC3)',
    scene=dict(
        xaxis=dict(title=f'Składowa Główna 1 (PC1) - {pca_3d.
 ↪explained_variance_ratio_[0] * 100:.2f}% Wariancji'),
        yaxis=dict(title=f'Składowa Główna 2 (PC2) - {pca_3d.
 ↪explained_variance_ratio_[1] * 100:.2f}% Wariancji'),
        zaxis=dict(title=f'Składowa Główna 3 (PC3) - {pca_3d.
 ↪explained_variance_ratio_[2] * 100:.2f}% Wariancji'),

        camera=dict(
            up=dict(x=0, y=0, z=1),
            center=dict(x=0, y=0, z=0),
            eye=dict(x=1.5, y=1.5, z=1.5)
        )
    ),
    margin={'l': 0, 'r': 0, 'b': 0, 't': 30}
)

data = [trace]
plot_figure = go.Figure(data=data, layout=layout)

py.iplot(plot_figure)
```

```
Skumulowana wariancja wyjaśniona dla 3 składowych głównych (PC1, PC2, PC3):
84.52%
```

Jaka będzie wartość skumulowanej wariancji wyjaśnionej dla dwóch składowych głównych, a jaka dla trzech?

Skumulowana wariancja wyjaśniona dla 2 składowych głównych (PC1, PC2): 72.23%

Skumulowana wariancja wyjaśniona dla 3 składowych głównych (PC1, PC2, PC3): 84.52%

Czy dodanie PC3 znacząco zmienia separowalność?

Moim zdaiem tak. To jest +- 12% unikalnych informacji, których nie możemy przekazać tylko za pomocą PC1 i PC2.

1.1.7 Dokumentacja:

- https://scikit-learn.org/stable/modules/generated/sklearn.decomposition.PCA.html
- https://numpy.org/devdocs/reference/generated/numpy.cumsum.html
- https://stackoverflow.com/questions/38364435/make-3d-plot-interactive-in-jupyter-notebook <—- wykres 3d

[9]:
```
# Eksportowanie bieżacego notatnika do pdf.

%run ../data/notebook_export
export_notebook_to_pdf("Projekt5_Nocoń_Filip.ipynb")
```

```
Export 'Projekt5_Nocoń_Filip.ipynb': OK.
```

```
<Figure size 640x480 with 0 Axes>
```

PDF wygenerowano: Wednesday, 10 December 2025 14:08:08